Universidade Federal de Mato Grosso do Sul

Inteligência Artificial — turma P03, 2026-2

Classificação de dígitos no dataset SVHN

Relatório do trabalho final

Samuel Vieira da Cunha Nahas
Wilker Sebastian Afonso Pereira
Bernardo Willian de Sousa Pereira

Professor: Wesley Nunes Gonçalves

Novembro de 2026

Resumo

Este relatório descreve a classificação dos dígitos do SVHN com redes neurais em PyTorch, usando só os conjuntos `train` e `test`. Partimos de um classificador linear (30,29% de validação) e de uma MLP (86,25%) e chegamos a uma CNN de três blocos com data augmentation, cutout, weight decay e label smoothing (96,68%). Toda escolha foi feita pela validação, numa divisão fixa do `train` com a semente 42. A solução final é um ensemble de 20 dessas CNNs, treinadas por 60 épocas com sementes fixas e avaliadas com deslocamentos de 1 e 2 pixels (TTA). Ela tem 97,52% de validação e 97,89% no teste, e é o modelo que gerou as predições do conjunto adicional. As mudanças de maior impacto foram trocar a MLP pela CNN, normalizar a entrada, usar data augmentation e combinar vários modelos.

1 Solução desenvolvida

Protocolo. O `split="train"` (73.257 imagens) foi dividido em 90% para treino (65.932) e 10% para validação (7.325), sempre com a semente 42. A normalização usa a média e o desvio de cada canal calculados só no treino. Cada modelo é avaliado na época de maior acurácia de validação. O `split="test"` (26.032 imagens) só informa a acurácia e não participa de nenhuma escolha, e o conjunto adicional do professor só foi usado depois que a solução final estava definida. Todos os modelos usam batch 64, taxa de aprendizado com decaimento cosseno ao longo das épocas e entropia cruzada, salvo quando o próprio experimento muda isso.

Semente. A semente 42 fixa a divisão treino/validação, a inicialização dos pesos, a ordem dos lotes e o augment, de modo que rodar de novo dá o mesmo resultado e todos os experimentos são comparados nas mesmas 7.325 imagens de validação. No ensemble, o membro i usa a semente $42 + i$ (42 a 61), numa ordem fixada antes de ver os resultados. A divisão continua sendo sempre a da semente 42.

Classificador linear. Uma camada linear de $3 \cdot 32 \cdot 32 = 3072$ entradas para 10 saídas (30.730 parâmetros), com softmax e entropia cruzada. Foi treinado com Adam, taxa de aprendizado 10^{-3}, por 15 épocas. Também testamos a loss SVM multiclasse da aula.

MLP. Duas camadas ocultas de 512 e 256 neurônios com ReLU (1.707.274 parâmetros), com as mesmas condições do linear: Adam, taxa de aprendizado 10^{-3}, batch 64 e 15 épocas. A partir dela variamos a taxa de aprendizado, o batch, o otimizador (SGD, com e sem momentum), as ativações, a normalização da entrada, a profundidade e a regularização (L2, Dropout e BatchNorm).

CNN. Três blocos de convoluções 3×3 com BatchNorm e ReLU, seguidos de max pooling (32, 64 e 128 filtros; a imagem vai de 32×32 a 4×4), e uma camada densa de 256 com Dropout 0,3. Sobre ela testamos data augmentation (rotação de $\pm 8°$, escala de $\pm 10\%$ e translação de $\pm 8\%$, sem espelhamento, porque um dígito espelhado é outro símbolo), filtros mais largos, weight decay, mais épocas, label smoothing, uma terceira convolução por bloco e cutout (um quadrado de 8×8 zerado em posição aleatória).

Hiperparâmetros mais importantes. Pelos experimentos, os que mais pesaram foram a taxa de aprendizado (com Adam, 10^{-2} impede o treino da MLP), a normalização da entrada, o data augmentation, o número de épocas e, na solução final, o número de modelos do ensemble. Batch, ativação ReLU contra Leaky ReLU e largura da CNN mudaram pouco.

Código. O notebook `svhn.ipynb` tem o classificador linear, as MLPs, as CNNs, o ensemble de 5, a solução final e as predições. Os treinos em lote (as triagens sobre a `cnn_best`, as confirmações com várias sementes e os ensembles de 60 épocas) usaram o script `dgx/svhn_dgx.py`, com o mesmo protocolo, a mesma divisão e a mesma normalização do notebook. O script confere a divisão antes de treinar.

Organização e metodologia. O trabalho foi feito no GitHub, em `https://github.com/SamuelNahas/svhn-classificacao`, onde estão o código, os pesos, os resultados de cada experimento e este relatório. Cada entregável virou uma issue, com as decisões do grupo registradas numa issue principal, e o andamento foi acompanhado num board, em `https://github.com/users/SamuelNahas/projects/2` (Backlog, Fazendo, Verificação e Pronto). Cada issue teve a sua branch e um pull request revisado antes de entrar. A cada pull request, a integração contínua executa o notebook inteiro num modo de teste rápido e confere as saídas. Nos experimentos, cada rodada mudou uma coisa por vez, e o plano e a regra de decisão de cada rodada foram registrados no repositório antes de rodar.

2 Experimentos

A Tabela 1 segue o formato pedido: cada linha parte da anterior e diz o que foi alterado, o resultado e se houve melhora ou piora em relação ao modelo anterior. A Tabela 2 traz os demais experimentos, agrupados por família, cada um comparado ao modelo de que deriva. Todas as acurácias são da melhor época de validação, e a escolha sempre foi feita pela validação. A Tabela 2 também traz a loss e a acurácia de treino de cada experimento; as dos modelos da Tabela 1 estão na Tabela 3 (Seção 3).

Tabela 1: Evolução até a melhor solução. Acurácias em %. A última coluna compara a validação com a linha anterior, em pontos.

#	Experimento	Modificação	Validação	Teste	Em relação ao anterior
1	Classificador linear	camada linear 3072→10, softmax	30,29	25,30	—
2	MLP baseline	MLP 512-256, ReLU, Adam lr 10^{-3}	86,25	82,88	melhorou (+55,96)
3	MLP + melhoria	SGD com momentum 0,9 e lr 10^{-2} no lugar do Adam	86,88	84,24	melhorou (+0,63)
4	CNN	3 blocos convolucionais (32/64/128 filtros) no lugar da MLP	95,33	95,21	melhorou (+8,45)
5	CNN + augment	data augmentation (rotação, escala e translação)	95,59	96,05	melhorou (+0,26)
6	`cnn_best`	+ weight decay, 30 épocas, label smoothing, 3 convoluções por bloco e cutout	96,68	97,05	melhorou (+1,09)
7	Ensemble de 5	média de 5 `cnn_best` (sementes 42–46)	97,06	97,51	melhorou (+0,38)
8	Ensemble de 5, 60 épocas	cada membro treinado por 60 épocas em vez de 30	97,39	97,71	melhorou (+0,33)
9	Ensemble de 20, 60 épocas	20 membros (sementes 42–61) em vez de 5	97,47	97,75	melhorou (+0,08)
10	**Solução final**	+ TTA shift12; membros retreinados no treino inteiro[a]	97,52	97,89	melhorou (+0,04)

[a] A validação da solução final é a do ensemble de 20 com TTA, com os membros treinados só no treino. Para a predição, os mesmos 20 foram retreinados com todo o `split="train"`, cada um até a melhor época de validação da sua semente, e é esse ensemble que tem o teste indicado. As linhas 7 a 10 são ensembles: a média do softmax de modelos iguais com sementes diferentes.

Tabela 2: Demais experimentos. Cada linha muda uma coisa em relação à base indicada. Loss: entropia cruzada. Acurácias em %. Ensembles não têm métricas de treino (—).

	Loss		Acurácia			
Modificação	treino	val.	treino	val.	teste	Em relação à base
MLP (base: `mlp_baseline`, salvo indicação)						
lr 10^{-4}	0,325	0,490	91,21	86,62	84,27	melhorou (+0,37)
lr 10^{-2}	2,238	2,225	18,83	19,70	19,59	piorou (−66,55)
batch 32	0,220	0,557	93,52	85,76	82,73	piorou (−0,49)

Modificação	Loss treino	Loss val.	Acurácia treino	Acurácia val.	Acurácia teste	Em relação à base
batch 256	0,195	0,520	94,95	86,59	83,87	melhorou (+0,34)
SGD sem momentum, lr 10^{-2} (base: Adam com a mesma lr)	0,456	0,554	87,27	84,66	82,33	melhorou (+64,96)
uma camada oculta de 100	0,366	0,518	89,83	85,84	83,77	piorou (−0,41)
camadas 1024-512-256 (base: BatchNorm + Dropout)	0,324	0,439	90,15	86,78	84,17	melhorou (+0,33)
Leaky ReLU	0,165	0,530	95,78	86,80	84,12	melhorou (+0,55)
tanh	0,545	0,801	83,61	75,41	72,23	piorou (−10,84)
sigmóide	0,387	0,597	88,56	81,69	79,09	piorou (−4,56)
sem normalização (só /255)	1,486	1,507	50,42	49,76	46,74	piorou (−36,49)
só subtrai a média	0,169	0,528	95,55	86,10	83,85	piorou (−0,15)
tons de cinza	0,175	0,529	95,19	86,66	83,65	melhorou (+0,41)
regularização L2, $\lambda = 10^{-4}$	0,258	0,499	92,86	86,31	83,64	melhorou (+0,05)
Dropout 0,3	0,418	0,530	87,38	84,60	81,61	piorou (−1,65)
Dropout 0,5 (base: Dropout 0,3)	0,597	0,657	81,86	80,26	76,79	piorou (−4,34)
BatchNorm + Dropout 0,3 (base: Dropout 0,3)	0,352	0,449	89,77	86,46	84,31	melhorou (+1,86)
classificador linear com loss SVM (base: linear)	2,101	2,153	28,33	27,58	23,64	piorou (−2,72)
CNN (base: `cnn_augment`); as que melhoraram formam a `cnn_best`						
filtros 64/128/256	0,117	0,175	97,36	95,48	96,12	piorou (−0,11)
weight decay 0,05	0,105	0,153	97,46	95,93	96,22	melhorou (+0,34)
30 épocas	0,060	0,161	98,54	96,01	96,37	melhorou (+0,42)
label smoothing 0,1	0,192	0,230	97,31	95,81	96,51	melhorou (+0,22)
3 convoluções por bloco	0,089	0,153	97,88	96,03	96,37	melhorou (+0,44)
cutout 8×8	0,128	0,163	96,87	95,82	96,00	melhorou (+0,23)
Sobre a `cnn_best` (base: `t01_ref_bf16`, a `cnn_best` no script em lote)[b]						
60 épocas	0,114	0,195	99,10	96,66	97,16	igual (+0,00)
média móvel dos pesos (EMA)	0,159	0,198	98,02	96,68	97,12	melhorou (+0,03)
brilho/contraste ±20%	0,130	0,193	98,88	96,83	97,09	melhorou (+0,18)
augment geométrico ×0,5	0,104	0,196	99,40	96,60	96,89	piorou (−0,05)
augment geométrico ×1,5	0,170	0,211	97,79	96,42	96,88	piorou (−0,23)
cutout 12×12	0,144	0,189	98,44	96,79	97,24	melhorou (+0,14)
cutout em metade das imagens	0,119	0,196	99,13	96,59	96,98	piorou (−0,07)
ResNet pequena (WRN-22-1)	0,142	0,197	98,57	96,63	97,27	piorou (−0,03)
Wide ResNet 16-4	0,127	0,198	99,21	97,08	97,46	melhorou (+0,42)
WRN-16-4 com SGD (base: WRN-16-4)	0,150	0,188	98,35	97,01	97,51	piorou (−0,07)
WRN-16-8 (base: WRN-16-4)	0,116	0,199	99,52	96,91	97,43	piorou (−0,16)
WRN-28-4 (base: WRN-16-4)	0,123	0,188	99,13	96,86	97,51	piorou (−0,22)
Confirmação com várias sementes (médias)[b]						
WRN-16-4 com 60 épocas (base: 30 épocas; 3 sementes)	0,114	0,204	99,55	96,86	97,60	piorou (−0,13)
CNN com 60 épocas (base: 30 épocas) em outra divisão (10 sementes)	0,101	0,196	99,60	96,78	97,10	melhorou (+0,10)
RandAugment no lugar do augment (base: CNN de 60 épocas; 3 sementes)	0,101	0,186	99,38	96,91	97,03	melhorou (+0,12)
AutoAugment SVHN (idem)	0,117	0,191	99,17	96,86	97,27	melhorou (+0,07)
TrivialAugment (idem)	0,109	0,196	99,33	96,68	97,05	piorou (−0,10)
Ensembles e TTA[b,c]						
TTA ±2 px no ensemble de 5 `cnn_best` (base: sem TTA)	—	—	—	97,31	97,57	melhorou (+0,25)
10 membros de 60 épocas (base: 5)	—	—	—	97,41	97,73	melhorou (+0,01)
30 membros de 60 épocas (base: 20)	—	—	—	97,42	97,76	piorou (−0,05)
TTA shift12 no ensemble de 20 (base: sem TTA)	—	—	—	97,52	—	melhorou (+0,04)

Modificação	Loss treino	Loss val.	Acurácia treino	Acurácia val.	Acurácia teste	Em relação à base
10 WRN-16-4 no lugar de 10 CNNs, ambos com shift12	—	—	—	97,28	—	piorou (−0,10)
20 membros mistos WRN e CNN no lugar de 20 CNNs, ambos com shift12	—	—	—	97,46	—	piorou (−0,05)

[b] Treinos em lote: a loss e a acurácia de treino são medidas numa amostra fixa de 7.325 imagens do treino, e a acurácia de teste foi calculada durante os treinos, mas só foi lida depois de a solução final estar fechada, sem influenciar nenhuma escolha. [c] TTA ±2 px: a imagem e 4 cópias deslocadas 2 pixels; shift12: a imagem e 8 cópias deslocadas 1 e 2 pixels. Com shift12, o teste só foi calculado para a solução final (—).

O que os experimentos mostram.

- **Família de modelo.** Linear, MLP e CNN são os maiores saltos: 30,29%, 86,25% e 95,33% na validação. O linear sobre pixels crus não separa os dígitos, e a CNN ganha por aproveitar a estrutura espacial da imagem.
- **MLP.** A normalização é essencial (sem ela, a validação cai para menos de 50%), a taxa de aprendizado 10^{-2} com Adam impede o treino, e tanh e sigmóide aprendem pior que ReLU. O SGD com momentum foi a melhor MLP (86,88%). Dropout sozinho reduz a diferença entre treino e validação, mas perde acurácia. Ao adicionar BatchNorm, a validação sobe para 86,46% e a diferença fica em 3,3 pontos percentuais.
- **CNN.** Data augmentation, weight decay, 30 épocas, label smoothing, a terceira convolução por bloco e o cutout melhoraram a validação isoladamente, e a `cnn_best` junta as seis. Filtros mais largos (4 vezes os parâmetros) pioraram e ficaram de fora.
- **Triagem em lote.** A Wide ResNet 16-4 foi a única mudança grande num modelo sozinho; redes residuais maiores não a superaram. EMA e mudar a intensidade do augment não ajudaram.
- **Épocas.** Com várias sementes, 60 épocas ganham de 30 na CNN, também numa segunda divisão que não guiou nenhuma escolha (96,68% → 96,78%). Na WRN-16-4, 60 épocas pioraram (96,98% → 96,86%). O augment automático (RandAugment, AutoAugment e TrivialAugment) não ganhou o bastante (a regra registrada exigia +0,15 ponto na média e a maioria dos pares).
- **Ensemble e TTA.** Combinar modelos foi o que mais rendeu depois da CNN. A curva da CNN de 60 épocas sobe até 20 membros e para (30 membros não ganham). A WRN, melhor sozinha, perde no ensemble, e o ensemble misto de WRN e CNN também não superou o de CNNs.

3 Curvas de treinamento

A Tabela 3 traz os resultados de treinamento e validação dos modelos principais, e as Figuras 1 a 5 mostram a loss e a acurácia de treino e validação por época.

Tabela 3: Resultados de treinamento e validação dos modelos principais (Tabela 1), na melhor época de validação. Loss: entropia cruzada. Acurácias em %. Diferença: acurácia de treino menos a de validação, em pontos.

	Loss		Acurácia			Melhor	
Modelo	treino	val.	treino	val.	teste	época	Diferença
Classificador linear	2,081	2,134	30,97	30,29	25,30	15/15	0,7
MLP baseline	0,179	0,560	95,08	86,25	82,88	15/15	8,8
MLP + melhoria	0,166	0,510	95,66	86,88	84,24	15/15	8,8
CNN	0,035	0,204	99,24	95,33	95,21	12/15	3,9
CNN + augment	0,112	0,167	97,27	95,59	96,05	14/15	1,7
`cnn_best`	0,135	0,198	98,78	96,68	97,05	24/30	2,1
membro da solução final (s42)[b]	0,107	0,194	99,39	96,60	97,23	54/60	2,8

[b] No treino em lote, a loss e a acurácia de treino são medidas numa amostra fixa de 7.325 imagens do treino.

Overfitting, underfitting e instabilidade. O linear tem underfitting (30,97% de treino e 30,29% de validação). A MLP baseline tem overfitting forte (95,08% de treino contra 86,25% de validação). Com Dropout e BatchNorm, a diferença cai para 3,3 pontos percentuais, com 86,46% de validação. A CNN sem augment também tem overfitting (99,24% contra 95,33%), e a regularização da `cnn_best` reduz essa diferença. A única instabilidade séria foi a MLP com Adam e taxa de aprendizado 10^{-2}: a loss fica parada em 2,24 desde a primeira época e a acurácia em cerca de 20% (Tabela 2). Com SGD e a mesma taxa, o treino converge.

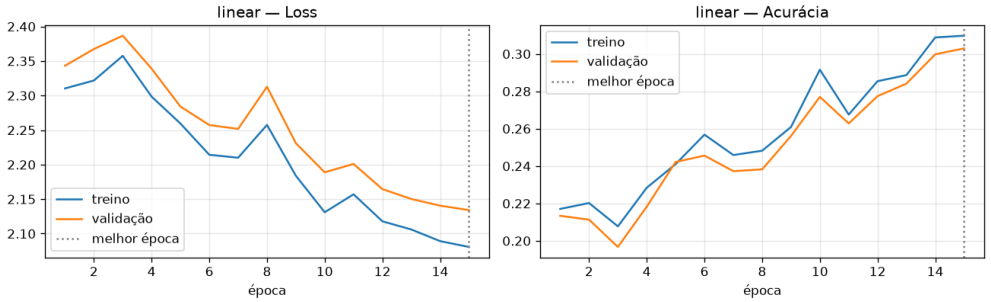


Figura 1: Classificador linear. Treino e validação ficam juntos e baixos (cerca de 30%): é **underfitting**, porque o modelo não tem capacidade para separar os dígitos.

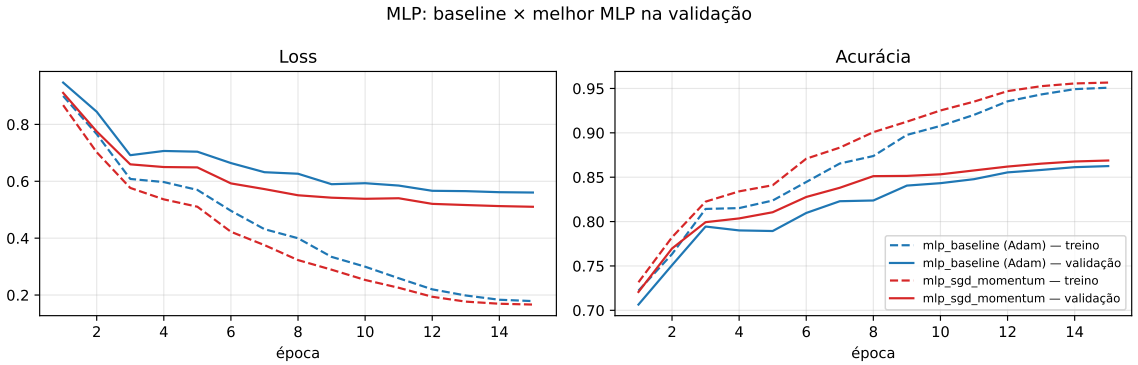


Figura 2: MLP baseline (Adam) e a melhor MLP na validação (SGD com momentum). A loss de treino continua caindo enquanto a de validação estabiliza, e a acurácia de treino passa da de validação por cerca de 9 pontos: **overfitting**.

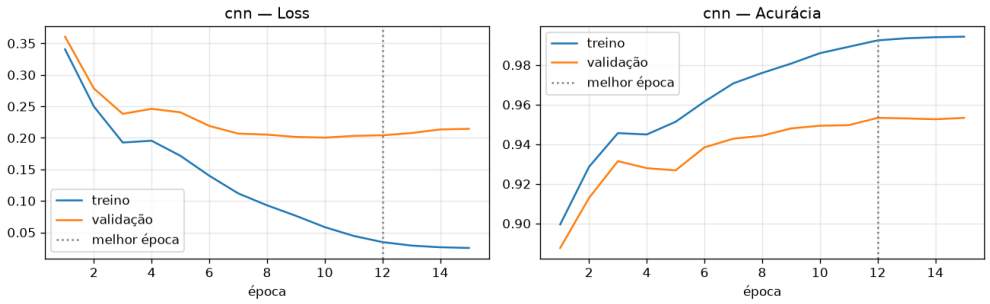


Figura 3: CNN sem augment. O treino chega perto de 100%, e a loss de validação atinge o mínimo na época 10 e volta a subir: **overfitting**, que o data augmentation corrige nas versões seguintes.

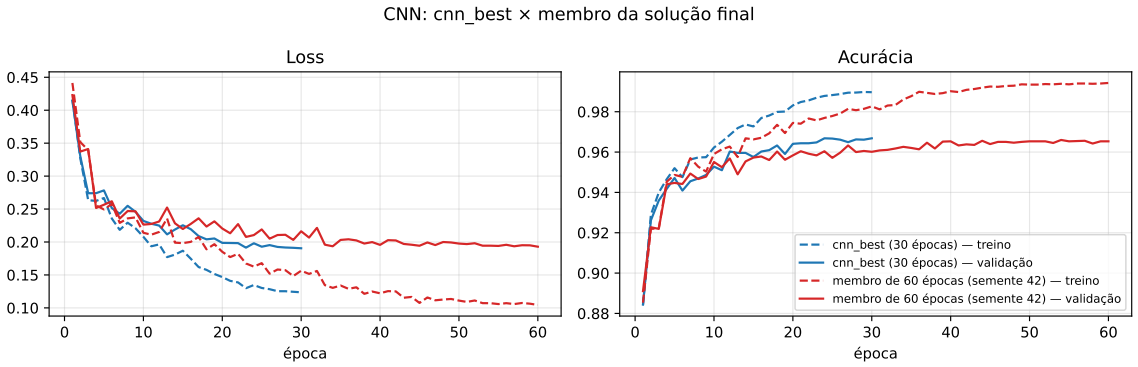


Figura 4: A `cnn_best` (30 épocas) e um membro da solução final (a mesma CNN, 60 épocas, semente 42). Com augment, cutout, weight decay e label smoothing, a diferença entre treino e validação é menor que na Figura 3 e a loss de validação não volta a subir. No membro de 60 épocas, as métricas de treino são medidas numa amostra fixa de 7.325 imagens do treino.

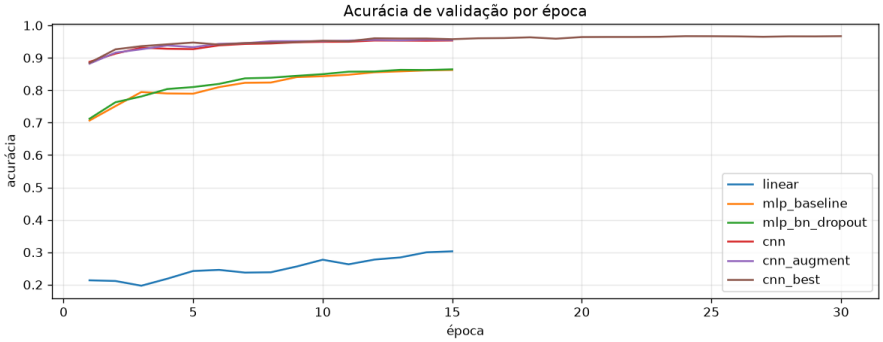


Figura 5: Acurácia de validação por época dos principais modelos.

4 Melhor solução

Arquitetura. Um ensemble de 20 CNNs iguais à `cnn_best`: três blocos de três convoluções 3×3 (32, 64 e 128 filtros) com BatchNorm e ReLU, max pooling depois de cada bloco, e uma camada densa de 256 com Dropout 0,3 antes da saída de 10 classes. Cada CNN tem 1.009.226 parâmetros, e o ensemble, 20.184.520. A predição é a média do softmax dos 20 modelos na imagem original e em 8 cópias deslocadas 1 e 2 pixels na horizontal e na vertical (TTA shift12), sem espelhamento.

Hiperparâmetros. AdamW com taxa de aprendizado 10^{-3}, weight decay 0,05, decaimento cosseno em 60 épocas, batch 64, label smoothing 0,1, data augmentation geométrico e cutout 8×8. As sementes são 42 a 61, uma por membro, e a divisão é sempre a da semente 42.

Treino final. Cada membro foi retreinado com todo o `split="train"` (treino e validação), como o enunciado permite, e parou na época em que o membro de validação da mesma semente teve a melhor validação (entre as épocas 40 e 60).

Acurácia. 97,52% de validação (linha 10 da Tabela 1) e **97,89% no teste**. A solução anterior, o ensemble de 5 `cnn_best` com TTA, tinha 97,31% e 97,63%, e uma única `cnn_best` retreinada, 96,68% e 97,13%.

Motivo da escolha. Foi a maior acurácia de validação entre todas as soluções testadas, e a regra de escolha foi registrada antes de ver os resultados. O número de membros é o menor em que a curva de validação já estabilizou (20; com 25 e 30, não ganha), e o TTA é o melhor na validação com 20 membros. Mais épocas também ganharam numa segunda divisão, que não guiou nenhuma escolha. O teste foi lido uma única vez, já com a solução fechada.

Predições e reprodução. É este o modelo que gerou o arquivo `SAMUEL_WILKER_BERNARDO_RESULTS.txt`: o notebook carrega os pesos dos 20 membros (`weights/pt4/`) e classifica automaticamente as 203.856 imagens do conjunto adicional, que nunca foram usadas no treino nem em nenhuma escolha. As acurácias e as predições se reproduzem exatamente a partir desses pesos, pelo notebook. Retreinar os membros com as mesmas sementes pelo script reproduz o resultado dentro de cerca de 0,1 ponto, porque o treino na GPU não é determinístico bit a bit.

5 Conclusão

O que funcionou melhor. A CNN regularizada, combinada num ensemble. Sozinha, a `cnn_best` chega a 96,68% de validação; o ensemble de 20 com TTA, a 97,52%, e 97,89% no teste.

Maior impacto. Em ordem: trocar a MLP pela CNN (de 86,88% para 95,33%); normalizar a entrada (sem ela, a MLP perde mais de 30 pontos); usar uma taxa de aprendizado adequada; data augmentation e as demais regularizações da `cnn_best`; e o ensemble com TTA, que reduziu o erro de teste de uma CNN sozinha em cerca de um quarto. Mudanças de capacidade (filtros mais largos e redes residuais maiores) renderam menos que regularizar e combinar modelos.

Dificuldades. Reduzir o overfitting da MLP sem perder acurácia de validação; a instabilidade do Adam com taxa alta; o custo de treino, já que a solução final tem 20 modelos de 60 épocas, o que nos levou a treinar vários modelos em paralelo na GPU; separar ganhos reais do ruído entre sementes (cerca de 0,1 ponto), o que exigiu repetir as melhores mudanças com mais sementes e registrar as regras de decisão antes de ver os resultados; e diferenças pequenas de predição entre a GPU e o CPU, que tornaram necessário gerar as predições finais sempre pelo mesmo código.